Extendiendo el Modelo Multidimensional

Mineria de datos

Luis Armando Vargas Peña

1. El espacio vectorial de las imágenes

Una imagen RGB de 256x256 píxeles se representa mediante un tensor de tamaño (256, 256, 3), donde los primeros dos valores representan el alto y ancho de la imagen y el tercero los colores rojo, verde y azul. Cada píxel tiene tres valores numéricos que normalmente van de 0 a 255.

Si convertimos la imagen en un solo vector, el número de dimensiones sería p = 256 x 256 x 3 = 196,608, esto significa que una sola imagen contiene 196,608 características numéricas que una red neuronal puede procesar para identificar patrones.

2. El espacio vectorial del texto (Word Embeddings / TF-IDF)

Los algoritmos no pueden comparar directamente palabras como "Feliz" y "Triste", por eso se utilizan técnicas que convierten el texto en vectores numéricos.

Una de ellas es TF-IDF, que asigna valores a las palabras dependiendo de su importancia dentro de un conjunto de documentos. Otra técnica son los Word Embeddings, que representan las palabras mediante vectores de números aprendidos por un modelo, de esta manera palabras como "Feliz" y "Alegre" pueden quedar cerca por tener significados similares.

- *Esto también se puede aplicar a oraciones completas y permite calcular qué tan parecidos son dos textos utilizando operaciones matemáticas.*

3. La maldición de la dimensionalidad

Cuando el número de dimensiones “p” aumenta a miles o millones, las distancias entre los datos pueden comenzar a parecerse demasiado, haciendo más difícil identificar cuáles usuarios realmente son similares.

Ejemplo de ello es la matriz X con Edad, Salario y Engagement podemos comparar usuarios utilizando la distancia euclidiana, pero si agregamos miles de variables las distancias tienden a concentrarse en valores similares, especialmente cuando los datos son aleatorios.

- *Esto afecta a algoritmos como k-NN porque se vuelve más difícil identificar a los vecinos más cercanos. Además necesitamos más datos y recursos para trabajar con tantas dimensiones, por eso se utilizan técnicas como PCA para reducir las variables conservando la información más importante.*

Referencias

- **Google for Developers.** (s. f.). *Introducción a las redes neuronales convolucionales.* https://developers.google.com/machine-learning/practica/image-classification/convolutional-neural-networks?hl=es-419
- **Google for Developers.** (s. f.). *Embeddings: espacio de embedding y embeddings estáticos.* https://developers.google.com/machine-learning/crash-course/embeddings/embedding-space?hl=es-419
- Murel, J., & Kavlakoglu, E. (s. f.). *¿Qué es la reducción de la dimensionalidad?* IBM. https://www.ibm.com/es-es/think/topics/dimensionality-reduction